程序设计竞赛组队推荐系统研究与设计

摘　要

大学生程序设计竞赛（如 ICPC、CCPC 等）在当下的高校中有着非常高的热度，能够有效的锻炼参赛选手的编程能力。竞赛以三人组队形式参加，然而目前学校内的队伍组成还是以相熟的同学互相组队为主，缺乏了组队的多样性和团队知识覆盖的全面性。与此同时，高昂的服务器价格与后续的维护费用阻碍了学校为集训队搭建专门的服务平台。

针对上述问题，本文设计了基于推荐系统和大数据处理技术的程序设计竞赛团队训练系统，为参赛选手提供了组队推荐、题目推荐、个人数据可视化等服务；为参赛团队提供了训练计划列表，团队知识覆盖程度可视化等服务；为学校提供了参赛队伍导出、构建竞赛代码库等服务。

系统主要包括四个部分：数据收集模块、大数据特征处理模块、推荐模块与系统业务模块。对各个模块所用技术以及功能作用说明如下：

（1）数据收集模块：分为离线数据收集与在线数据收集。离线收集采用 go-colly 框架分布式爬取用户在 Codeforces 等程序竞赛网站的提交记录；在线收集使用 zap 与 lumberjack 进行日志的收集与切割。

（2）大数据特征处理模块：离线收集的数据上传到 HDFS 中进行存储。Spark 使用这些数据生成 Embedding 向量供接下来的模型训练使用。

（3）推荐模块：使用 TensorFlow 训练 NerualCF 模型与双塔模型，并通过 TensorFlow Serving 提供 gRPC 和 RESTful API 调用。

（4）系统业务模块：前端使用 Vue.js + Vite + Element-Plus UI 完成业务页面的开发与设计；使用 Go 语言的 Gin 框架完成后端开发，它是连接起整个的系统的桥梁，完成了响应前端请求、记录日志、特征拼装、请求模型服务 API 等任务。

关键词　程序设计竞赛；推荐系统；大数据处理；Embedding；

Research and Design of Team Recommendation System for Programming Competition

Abstract

Collegiate Programming Contest (such as ICPC, CCPC, etc.) has a very high heat, can effectively exercise programming capabilities contestants. The competition is in the form of a three-person team, but currently it is mainly a team of acquaintances, which lacks the diversity of the team and the comprehensiveness of the team's knowledge coverage.

To solve the above problems, this paper designed a team training system based on the recommendation system and big data processing technology to provide team recommendation, title recommendation, personal data visualization and other services for the competitors. Provides the team training program list, team knowledge visualization services covering degree; Provides for the school teams export, build competition code library services.

The system mainly includes four parts: data collection module, big data feature processing module, recommendation module and system business module.

1. Data collection module: Divided into offline data collection and online data collection. Offline collection uses the go-colly framework to crawl user submission records on Codeforces and other program competition websites; real-time collection uses zap and lumberjack to collect and cut logs.

2. Big data feature processing module: Data collected offline is uploaded to Hadoop HDFS storage for Spark's next data processing.

3. Recommended module: Use TensorFlow to train the NerualCF model and the twin tower model, and provide gRPC and RESTful API calls through TensorFlow Serving.

4. System business module: The front-end uses Vue.js + Vite + Element-plus UI to complete the development of business pages; Use Gin framework development after the completion of the end, it completed response front-end request, logging, characteristics, model service API and other tasks.

Keywords Programming contest, Recommendation system, Big data processing, Embedding;

目 录

第1章 绪论

1.1 研究背景及意义

据最新统计，我国互联网使用人数达到 9.89 亿，覆盖了全国 70.4%的人口，是世界上最大的互联网使用群体（截止至 2020.12）[1]。庞大的使用人数，使得如今的互联网有着“人数多、范围广、场景杂”的特点，从而对高校所培养的计算机人才素质提出了更高的要求。

程序千变万化，不变的是它的内在逻辑与思维方式。算法作为程序设计的灵魂所在，在近些年越来越受到国内外高校的重视与青睐。于是各项程序设计竞赛应运而生，高校希望能够通过算法竞赛来以赛促学，激发学生们学习算法的积极性，为学生之后的工作或学术研究打下良好的基础。

国际大学生程序设计竞赛（ICPC）是一项久负盛名的世界性编程赛事，在高校中有着非常高的热度[2]。参加算法竞赛能够有效的锻炼参赛选手分析问题的建模能力与算法实现的编程能力。竞赛以三人团队形式进行，挑战在 5 小时内编程解决 8-13 道复杂问题，十分考验团队成员的协同配合能力。然而笔者在经过实际的竞赛训练经历与观察之后，发现在训练与组队的环节还存在着若干问题：

（1）个人训练问题：“题量过大，信息过载”。在程序竞赛高度火热的今天，早已不是 10 年前只有少数几个经典在线测评平台（Online Judge, OJ）的时代了。Codeforces、POJ、HDU 等 OJ 上的题目集都在 7000-8000 道左右，这个数量还在不断增长当中。参赛选手很难在如此庞大的题目集中合理挑选出自己所需要的训练题目。

（2）团队组合问题：“熟人互组，依赖经验”。在每届新生入学之后，因为互相间还不熟悉，人们更倾向于选择自己的同班同学组队。而对于不同班级之间，缺少一个平台能够让其互相了解编程水平和擅长方向。

（3）团队训练问题：“缺乏计划，定位不明”。团队在进行训练时，大多都是在被动接受训练安排，缺乏明确且有针对性的训练计划来补齐短板、攻克难关。团队成员在队内的分工方法也时常不明确。

（4）学校集训队问题：“工作繁琐，资源分散”。教练的工作繁重，从训练计划到比赛安排，经常使用 Excel 表格处理大量数据，数据可视化。整个集训队训练资源分散在 QQ 群中，每一届的队员都会自己制作一些代码模板或经验总结，但是并没有得到很好的应用。

在处理架构上，高昂的服务器价格与后续的维护费用阻碍了学校为集训队搭建专门的服务平台。分布式大数据平台的出现为其提供了一种较为

经济实惠的解决方案。开源框架 Apache Hadoop 可以使用多台廉价的机器组成一个分布式集群，它的三个核心组件 HDFS、Yarn、MapReduce 构成了大数据处理的三驾马车。HDFS 提供了分布式文件存储，Yarn 管理整个集群的资源和任务调度，MapReduce 实现分布式的并行计算。大数据批处理平台 Spark 的出现解决 MapReduce 运行效率低下的痛点，为更快的分布式处理数据提供了支持。这些技术的出现与成熟，为本论文的设计与实现提供了有力支撑。

综上所述，在程序设计竞赛盛行背景下，针对竞赛团队组成过程中所存在的问题，设计基于推荐系统和大数据处理技术的组队推荐系统，对参赛选手们的学习与比赛，有如下几点意义。

（1）对参赛选手：提供题目推荐，使其不再陷入茫茫题海；提供队友推荐，扩大视野范围，选择更适合自己的队友；个人数据可视化，让长处短板一目了然，更清晰的认知自己的实力。

（2）对参赛团队：提供了训练计划列表，让团队的实力提升有条不紊；提供团队知识覆盖程度可视化，及时发现存在的短板，取得更好的成绩。

（3）对集训教练：提供了各个队伍训练情况可视化面板，训练情况轻松掌握；构建集训队知识库，让每一届学生们的知识汇聚于此，薪火相传。

（4）对系统搭建：利用大数据技术，让平台不在依赖昂贵的专用服务器。通过集群也可以支撑起海量日志的存储、处理与分析。

1.2 国内外研究与发展现状

1.2.1 推荐系统研究与发展现状

协同过滤作为推荐算法中影响力最大、应用最广泛的模型，其研究可以追溯到 1992 年[3]。Xerox 的研究中心开发了一种邮件筛选系统，用来过滤一些用户不感兴趣的无用邮件，协同过滤（Collaborative Filtering, CF）算法第一次出现在了人们的视野中。但是协同过滤在互联网领域大放异彩，还是源于电商巨头 Amazon 对于协同过滤的应用。2003 年，Amazon 发表了工业界的知名论文 Amazon.com Recommenders Item-to-Item Collaborative Filtering[4]，这不仅让 Amazon 的推荐系统广为人知，更让协同过滤成为很长时间的研究热点和业界主流的推荐模型。协同过滤可以根据相似度计算对象的不同分为 UserCF 和 ItemCF。其中 UserCF 更符合人们直觉上“兴趣相似的朋友喜欢的物品，我也喜欢”的思想，但是从技术的角度，也存在一些缺点。首先是为了快速找出 Top n 相似用户，维护的用户相似度矩阵会以 n^2 的速度快速增长，对存储系统造成了十分巨大的压力。其次针对用

户稀疏历史行为时的准确率非常低，在用户反馈困难的领域或是新加入的用户效果不佳。而 ItemCF 同样也存在着自己的问题：不具备很强的泛化能力，无法将两个物品相似这一信息推广到其他物品的相似度计算上，从而导致热门物品强烈的头部效应和冷门物品无法得到足够的推荐。

2006 年，矩阵分解算法（Matrix Factorization, MF）在 Netflix 举办的奖金挑战赛中表现出色。主要优点在于其利用矩阵分解解决了 CF 模型在处理稀疏矩阵上的不足。矩阵分解方法分为利用特征值分解、奇异值分解和梯度下降。但 MF 算法依旧没有解决如何将更多的特征（如上下文信息）加入推荐模型中。

逻辑回归模型解决了特征融合的问题，它不再依靠相似度计算去对推荐列表进行排序，而是期望将用户的点击率（Click Through Rate，CTR）概率作为推荐排序的基础。2012 年，阿里巴巴提出将推荐样本进行分片，然后在每片中进行 LR 的运算，最终将加权平均概率作为最后的预估值，该模型被称作大规模分段线性模型（LS-PLM）[5]，这已经很接近于三层的神经网络，在深度学习的浪潮席卷之前发挥出惊人的效果。但是基于 LR 的推荐模型没有实现交叉特征的处理，有可能在某些情况导致辛普森悖论，出现每种特征的 CTR 概率都很高，但是综合之后反而很低的情况。

为了解决特征交叉的问题，人们从一开始的手动组合到 POLY2 模型将所有特征两两暴力组合，直到 2010 年 FM 模型提出通过引用两个特征隐向量内积作为交叉特征的权重，这才真正解决了特征交叉无法实际应用的问题[6]。传统推荐模型三大模型的演化关系如图 1-1 所示：

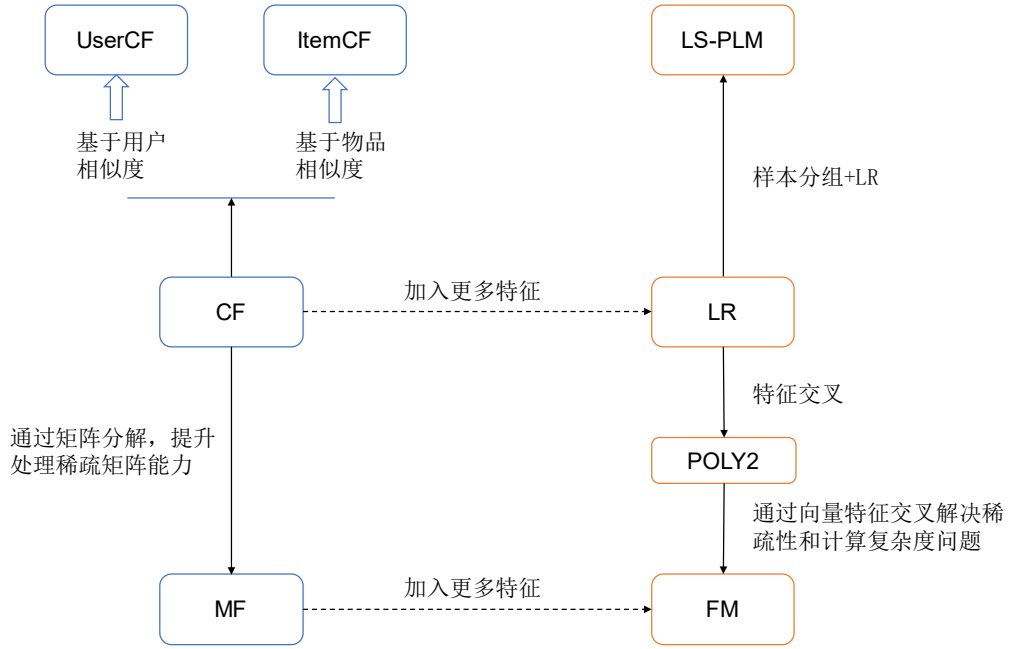

图 1-1 传统推荐模型演化关系图

随着 Alex Krizhevsky 在 2012 年提出了 AlexNet，开启了深度学习的时代[7]，推荐算法也深受其影响。而 Google 于 2013 年提出的 Embedding 技术—Word2Vec，解决了传统特征输入中采用 One-hot 编码导致的矩阵稀疏问题[8]。Barkan 等人在 2016 年提出的 Item2Vec，让 Embedding 技术从词扩展到序列，更加适应了推荐系统的应用场景[9]。但是这些 Embedding 方法还都是仅仅支持序列信息，无法覆盖图这种复杂的结构。2014 年 DeepWalk 算法采用随机游走的方法将图模型转化为序列模型，成功的解决了 Embedding 无法运用在图结构的缺点。但随机游走产生的抽样性不强。这个问题再 2016 年被来自斯坦福大学的 Grover 等人解决[10]，提出了 Node2Vec 方法，通过调整游走过程的倾向性来实现相应场景的适应。2018 年阿里巴巴公布其 Graph Embedding 的模型 EGES，从工程学的视角解决了多 Embedding 的融合问题[11]。

在推荐算法的实际应用中，张廉月完成了基于 Flink 流处理框架的电影推荐系统的设计，其通过分布式大数据计算平台 Apache Spark、Apache Flink 以及多种开源软件，如文档数据库 MongoDB、缓存服务器 Redis、搜索引擎 Elastic Search、消息中间件 Kafka 等，搭建完整的大数据处理系统[12]。景坤使用了推荐系统完成了网约车组队的设计与实现[13]，胡开冉[14]提出了基于 FunkSVD 的反向推荐可以大大提高物品的覆盖率，解决推荐算法中的长尾效应。李斌提出一种基于迁移学习的领域自适应推荐方法用于赛事推荐[15]。

1.2.2 推荐算法在算法竞赛领域的研究现状

到目前为止，很少有专注于算法竞赛推荐领域的研究：2014 年 Toledo 等人提出了一种基于传统协同过滤的方法，并采用了适合案例的新相似度度量[16]。Year 等人在 2018 年提出基于模糊逻辑的方法[17]。Caro 和 Jimenez 等人考虑了基于用户相似性的方法来进行题目的推建[18]。2020 年 fantozzi 等人使用了欧洲学生在意大利信息学奥利匹克竞赛上的数据训练了基于自动编码器神经网络的 ANN 模型，并测试两种不同的方法，离线数据和经过改动的增量数据，在运用深度学习推荐题目中做出了尝试[19]。

国内对于在 OJ 中进行题目推荐的尝试有：2015 年孙权提出使用协同过滤算法进行题目推荐[20]，2018 年朱国进等人采用的基于关联规则挖掘的方法进行推荐[21]，2019 年肖春芸等人在华东师范的 EOJ 平台上使用基于用户的协同过滤算法，来为学生生成推荐题目路径[22]。知名在线测评平台 LeetCode 也提供了热门题目推荐功能。这些尝试都是基于传统的推荐算法，受到的局限性较大，往往无法真正的对每一个训练队员进行个性化的服务。

1.3 论文的主要工作

本文首先分析了目前程序设计竞赛各个环节中存在的不足，从个人训练、团队组合到教练员的繁重工作。然后从三个不同的视角给出对应的解决方法。最后使用了大数据技术和基于 Embedding 与深度学习的推荐算法，在程序设计竞赛组队推荐领域做出了一次尝试。以上三点也是本论文的创新所在。希望该系统设计与实现可以有效的帮助到集训队的同学进行更高效的训练以及减轻教练员重复性的劳动。

系统主要包括四个部分：数据收集模块、大数据特征处理模块、推荐模块与系统业务模块。现对各个模块所用技术以及功能作用说明如下：

（1）数据收集模块：分为离线数据收集与在线数据收集。离线收集采用 go-colly 框架分布式爬取用户在 Codeforces 等程序竞赛网站的提交记录；在线收集使用 zap 与 lumberjack 进行日志的收集与切割。

（2）大数据特征处理模块：离线收集的数据上传到 Hadoop HDFS 进行存储。Spark 使用这些数据生成 Embedding 向量供接下来的模型训练使用。

（3）推荐模块：使用 TensorFlow 训练 NerualCF 模型与双塔模型，并通过 TensorFlow Serving 提供 gRPC 和 RESTful API 调用。

（4）系统业务模块：前端使用 Vue.js + Vite + Element-Plus UI 完成业务页面的开发与设计；使用 Go 语言的 Gin 框架完成后端开发，它是连接起整个的系统的桥梁，完成了响应前端请求、记录日志、特征拼装、请求模型服务 API 等任务。

1.4 论文的组织结构

本文共分为 6 章，各章节的安排如下：

第一章为绪论，首先介绍了本论文的研究背景及其意义。然后对推荐系统国内外的研究发展进行了梳理，调查了目前推荐算法在程序设计竞赛领域的研究进展。最后简要说明本文的主要工作和组织结构安排。

第二章

第2章 相关技术与理论基础

2.1 推荐算法理论研究

2.1.1 基于内容的推荐算法

基于内容的推荐算法结构简单、历史悠久，如今依旧在很多场景下表现良好。整个算法的核心思想就是为用户 X 推荐之前喜欢的物品相似的物品列表 Y。下图 2-1 展示了基于内容推荐算法的 Codeforces 题目推荐流程：

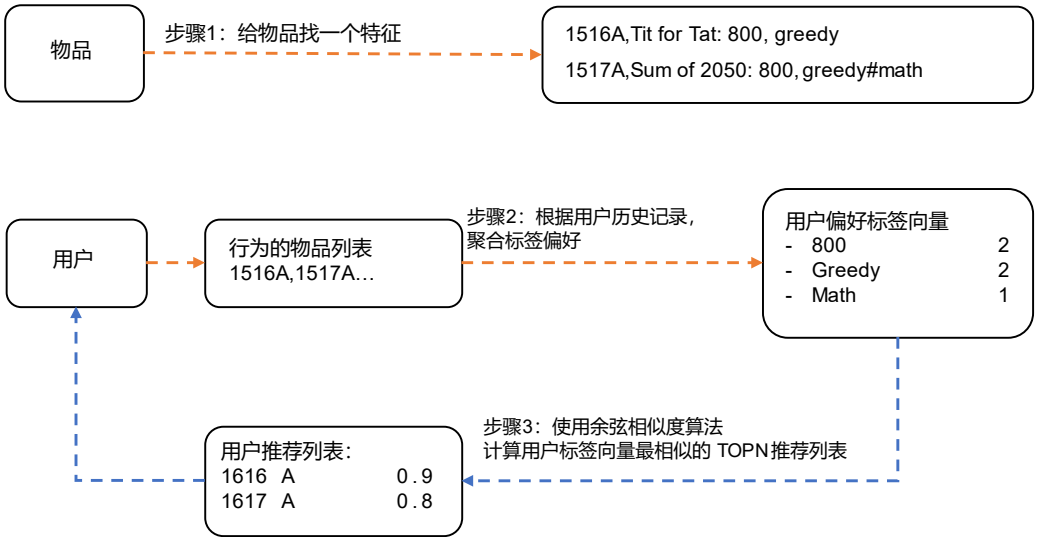

图 2-1 基于内容推荐算法流程

（1）步骤一：为每个物品找一个特征，如难度系数、分类标签等。

（2）步骤二：收集用户的历史提交记录，比如用户 A 做过 1516A、1517A 这两道题，将题目列表标签做聚合统计，形成用户的偏好标签向量。

（3）步骤三：利用余弦相似度算法，计算与用户的偏好标签向量最接近的 TopN 列表（如上图 1616A 这道题和用户的偏好相似程度 90%，非常可能在选择做），然后推荐给用户。

其优缺点分析如下表所示：

表 2-1 基于内容推荐算法优缺点分析

优点	缺点
不需要其他用户的数据	一直处在舒适圈之中，不断推荐水题
不存在冷启动问题	推荐的同质化现象严重
推荐结果直观易于解释	无法与更多的特征交叉融合

2.1.2 常用向量相似度计算方法

在上文步骤三中提到了计算用户偏好向量和物品向量的相似程度，下面列举出几种常用的相似度计算方式，并对其含义进行说明。

（1）**余弦相似度**：如（式 2-1）所示，通过度量两个向量夹角的 cos (θ)值来表示向量之间的相似程度。余弦相似度计算简单迅速，并且在高维的情况下依旧适用。

$$\cos(\theta) = \frac{\sum_{k=1}^{n} x_{1k}x_{2k}}{\sqrt{\sum_{k=1}^{n} x_{1k}^2}\sqrt{\sum_{k=1}^{n} x_{2k}^2}} \tag{2-1}$$

（2）**皮尔逊相关系数**：如（式 2-2）所示，在利用余弦相似度进行计算的时候，若用户没有评价的物品分数会被直接判 0，这么做的后果会导致原本高分和低分的物品在计算完相似度后特别靠近。而皮尔逊相关系数将用户还未评分的物品填充样本均值，然后再计算余弦相似度。

$$\mathrm{sim}(x_1, x_2) = \frac{\sum_{k=1}^{n} \left(x_{1k} - \bar{x_1}\right)\left(x_{2k} - \bar{x_2}\right)}{\sqrt{\sum_{k=1}^{n} \left(x_{1k} - \bar{x_1}\right)^2}\sqrt{\sum_{k=1}^{n} \left(x_{2k} - \bar{x_2}\right)^2}} \tag{2-2}$$

（3）**Jaccard 相关系数**：如（式 2-3）所示，杰卡德相似系数从集合的角度衡量相似度，计算方法是看相同元素占总体的比例。而杰卡德距离（式 2-4）与之恰恰相反，用不同元素占总体比例来衡量两个集合的区分度。

$$J(\mathrm{A}, \mathrm{B}) = \frac{|A \cap B|}{|A \cup B|} \tag{2-3}$$

$$J_\delta(A, B) = 1 - J(A, B) = \frac{|A \cup B| - |A \cap B|}{|A \bigcup B|} \tag{2-4}$$

无论选取哪种相似度计算方式都需要具体问题具体分析，灵活的相似度算法使用可以帮助我们有效提升推荐的效果。

2.1.3 基于协同过滤的推荐算法

协同过滤（Collaborative Filtering）的推荐依据是使用行为数据，利用集体的智慧来进行推荐。UserCF 与 ItemCF 的区别与联系如下图 2-2 所示：UserCF 是根据找到和你兴趣接近的人，将他们喜欢的其他物品推荐给你，ItemCF 是找到与你所喜欢物品类似的物品，然后推荐给你。左图中 User1、User2、User4 都喜欢 Item1 和 Item2，那么认为这三个人的兴趣相同，当 User2 和 User4 新喜欢一个物品 Item4 时，便把此物品推荐给 User1。右图中 User2 和 4 同时喜欢 Item2 和 Item3，系统便认为 Item2 和 3 是相似物品。当 User1 喜欢 Item2 时，系统也会把 Item3 也推荐给他。

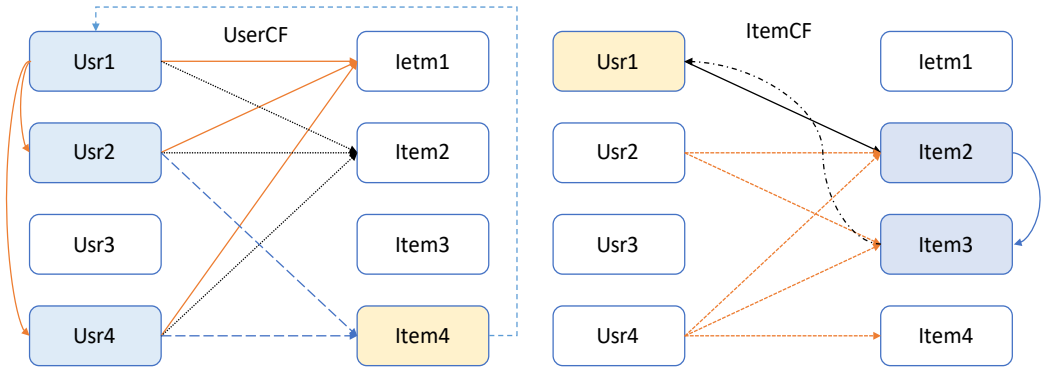

图 2-2 UserCF 与 ItemCF 原理

在获得了 TopN 个相似用户之后，我们就可以轻易的获得用户对于其还没有评价的物品的预估值。其实现方式通常为利用其他用户 s 对该物品 p 的评分的加权评分，权重 w 为其他用户 s 与推荐用户 u 的相似度，最终得到用户 u 对于物品 p 的预估评分。整个过程如（式 2-5）所示，

$$R_{u,p} = \frac{\sum_{s \epsilon S} \left(w_{u,s} \cdot R_{s,p}\right)}{\sum_{s \in S} w_{u,s}} \qquad (2-5)$$

协同过滤算法虽然经典，但是缺点也是显而易见的，比如上图 2-2 里的 Uer3，当他还未对某个物品进行评分时就无法找到与他相似的用户，这就是推荐系统中常见的冷启动问题。还有在物品数量和用户数量特别多的时候，维护用户-物品评分矩阵对存储的压力极大，所以许多公司选择了 ItemCF 作为其推荐算法。

ItemCF 的具体流程如下：

（1）获得用户的历史行为信息，组成 M×N 维的用户-物品矩阵

（2）以列为向量，通过皮尔逊相关系数计算物品之间的相似程度，最终构建出 N×N 维的物品相似度矩阵。

（3）获得用户的喜爱列表（正反馈可以靠与平均值相比来界定）

（4）针对目标用户 u 的喜爱列表，分别每个对已评价物品生成 TopN 个相似物品，组成相似物品候选集。

（5）对相似物品候选集里面的物品，对其按照加权后的总相似度进行排序，最终生成排序列表。加权公式如（式 2-6）所示：

$$R_{u,p} = \sum_{h \in H} (w_{p,h} \bullet R_{u,h}) \qquad (2-6)$$

其中 $R_{u,p}$ 是目标用户 u 对未评分物品 p 的预估情况，H 是用户 u 的喜爱物品集合，权重 $w_{p,h}$ 是未评分物品 p 与已评分物品 h 的相似度，$R_{u,h}$ 是用户 u 对 h 的评分。

下表 2-2 是 UserCF 和 ItemCF 各自的优缺点与适用场景

表 2-2 UserCF 与 ItemCF 优缺点分析

	优点	缺点
UserCF	1. 基于用户相似度进行推荐，有着更强的社交属性。 2. 适用于发现热点，以及跟踪热点的发展趋势。	1. 用户的历史行为可能非常稀疏，找到相似用户的准确率很低。 2. 用户相似度矩阵的维护非常消耗资源，在线存储系统难易承受。
ItemCF		

2.1.4 协同过滤的优化—矩阵分解

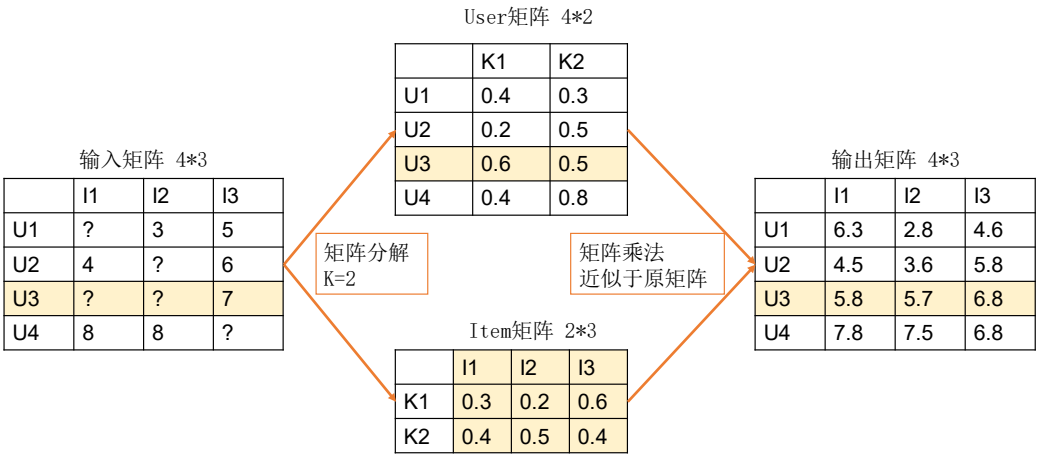

2.1.5 Embedding 在推荐系统中的应用

Embedding 技术
Word2Vec
Item2Vec
局部敏感哈希

2.1.6 深度学习在推荐系统中的应用

Embedding + MLP
NeuralCF
双塔模型

2.2 推荐系统评测

2.2.1 评测方法

2.2.2 评测指标

2.3 大数据处理架构

2.4 本章小结

第3章 程序设计竞赛组队推荐系统分析

3.1 需求分析

3.1.1 功能性需求

3.1.2 非功能性需求

第4章 程序设计竞赛组队推荐系统设计

4.1 系统架构设计

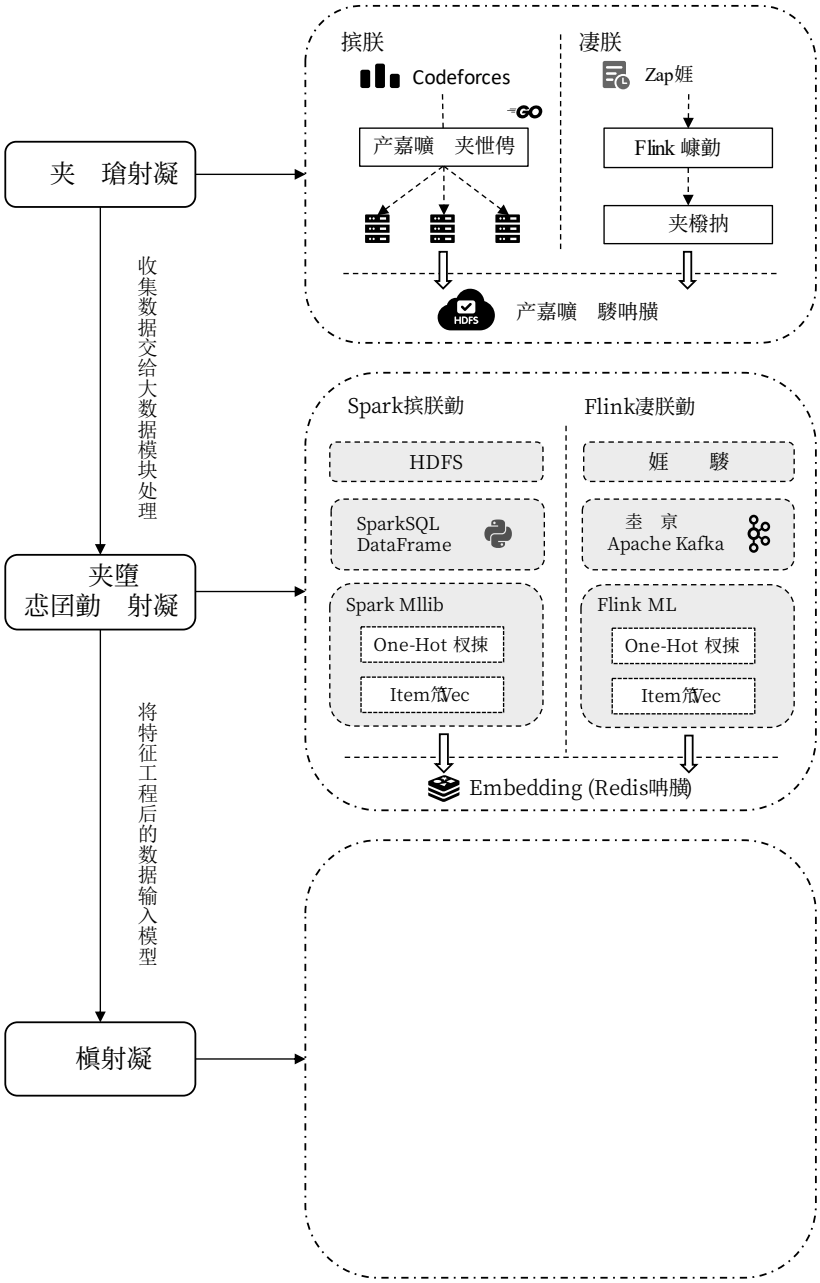

4.2 系统开发环境

前端使用 Vue3.0+Vite2.0+ElementPlus UI 在 Windows 10 系统完成开发，开发工具使用 Vscode；后端使用 Go 语言在 CentOS 8 服务器上完成开发，开发工具使用 Goland；大数据部分采用一台 2 核 4G 内存与两台 1 核 2G 内存的云服务器构成完全分布式的集群部署，操作系统均为 CentOS 8.0；模型训练使用 GPU 服务器完成，显卡型号 GeForce RTX 3090，显存 24GB。

4.3 数据收集模块

谷歌的研发总监 Peter Norvig 曾说过：“更多的数据优于更好的算法，而好的数据优于多的数据”。这句话强调了数据对于整个系统至关重要。本次设计需要使用离线与在线的数据为队员们进行推荐，离线数据主要来源于 Codeforces 训练记录的爬取；在线数据主要来源于用户在网站上操作（构建知识库、提交题解、回复问题等），需要通过埋点日志记录并通过消息队列传递给 Flink 进行消费。下面介绍数据爬取模块时的技术选型和选取原因。

4.3.1 编程语言 Golang

Golang（简称 Go）是由 Google 公司的 Robert Griesemer，Rob Pike 和 Ken Thompson 在 2009 年开源的一种编程语言，并于 2012 年 3 月发布了第一个稳定版本。

为什么本文选择 Go 作为系统开发的主要语言？

1. 性能优势：简单是 Go 语言的核心，这意味着它可以快速编译，快速运行并且快速上手开发。实测中 Go 拥有着近乎 C++的编译速度与 Python 的开发效率。

2. 并发：独特的并发设计是 Go 区别其他语言的最大特点。Go 的并发哲学源自 CSP 理论[23]，选择 Channel 通信而不是加锁来控制共享资源，从设计上避免了数据竞争的问题。而并发的基本单位协程 Goroutine 相比线程来说，避免了操作系统内核对线程的调度，减少了大量 CPU 用来保存上下文和恢复现场的时间，对操作系统完全透明。这也是 Go 在编写 HTTP 服务器方面表现出色的主要原因之一。

3. 跨平台且易于维护：Go 编译生成的二进制文件可以在 Windows，Linux，macOS 或其他平台上直接运行，降低了部署的难度。

4.3.2 爬虫框架 Go-Colly

由于整个服务端由 Go 语言构建，便没有选择知名的 Python 爬虫框架 Scrapy，而是采用了 Go 语言的 Colly 爬虫框架。下表 2-1 展示了两者之间的差异：

表 4-1 爬虫框架 Colly 与 Scrapy 对比

对比内容	Colly	Scrapy
爬取速度	较快	较慢
API 设计	简洁	每个版本都有改变
并发支持	原生支持	需要配置
Robots 协议支持	有	有
分布式支持	支持	需要配置
解析库支持	Goquery	Pyquery / BeautifulSoup 等
定时任务	不支持	支持
扩展性	不支持	有许多第三方扩展

相较于 Scrapy 而言，作为一个新生爬虫框架，依靠着 Go 语言强大的并发性能和简洁的语言风格，在爬取速度和使用难易程度上都有一定优势。但是在可扩展性和爬取后数据的分发，都和生态完整的 Scrapy 框架有着一定的差距。

4.3.3 定时任务 Cron

由于 Go-Colly 框架不支持定时任务，结合笔者三台服务器被挖矿木马入侵时 crontab 文件被异常写入的经历，发现了 Go-Cron 库。其实现了类似于 Linux 系统 Crontab 服务的功能，利用这一功能完成了自动化定时爬取。

使用 Cron 不仅仅能够实现定时任务，还支持为定时任务自定义许多其他功能，让爬虫服务变成更加稳定以及便于维护。下表 2-2 列举了这些功能和实现意义：

表 4-2 Cron 自定义功能及其意义

功能	意义
WithLocation	指定时区
WithParser	使用自定义的解析器
WithLogger	自定义 log 来记录任务运行情况
ThreadSafe	显式的处理回调
WithChain	自定义 JobWrapper，可以用来捕获异常、恢复上次未执行完的 Job、跳过失败任务等

4.3.4 日志收集 Zap

Go 官方提供的日志库 Go Logger 虽然使用起来非常的简单，但是仅支持基本的日志事件，不支持输出 INFO、DEBUG 等多个日志等级。对于错误事件也仅仅是在抛出 panic 之前记录一条日志，缺少 ERROR 日志等级，无法在不退出程序的情况下记录错误。同时输出的日志不支持格式化，对接下来的数据处理和分析造成影响。所以选择了开源日志库 Zap 来对用户产生的点击事件进行记录。Zap 针对语言底层，实现了一个无反射，零分配的 JSON 编码器，减少了在序列化数据时造成的时间开销。下表 2-3 展示了 Zap 与其他 Go 语言日志库的性能差距：

表 4-3 Zap 与其他日志库性能对比

Package	Time	Time % to zap	Objects Allocated
zap	**862 ns/op**	**+0%**	**5 allocs/op**
zerolog	4021 ns/op	+366%	76 allocs/op
go-kit	4542 ns/op	+427%	105 allocs/op
apex/log	26785 ns/op	+3007%	115 allocs/op
logrus	29501 ns/op	+3322%	125 allocs/op
log15	29906 ns/op	+3369%	122 allocs/op

从上表可以看出，Zap 极大的减少了每次操作所需要的资源分配，比另一个热门日志库 logrus 性能提升了 33 倍。在实用性方面，Zap 也弥补了上述所提到的官方库缺点，让我们可以随意的定制所需要的日志输出。

4.4 大数据特征处理模块

随之收集而来的数据越来越多，单个服务器可能无法保证数据的可靠存储。大数据技术是整个系统数据存储、清洗与训练中不可缺少的一环。本次设计采用的大数据技术相互之间的联系如下：

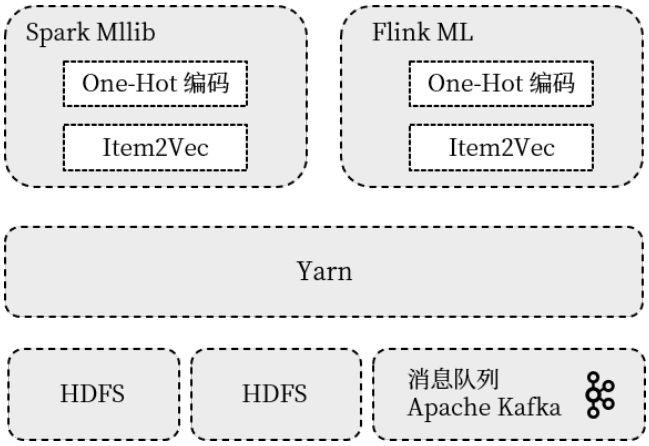

图 4-1 大数据技术关系图

如上图 2-1 所示：Hadoop HDFS 作为分布式文件存储，是所有落盘数据最终的去处。Yarn 作为资源调度和任务分配的中心对 Spark 的任务进行管理。而 Spark Mllib 分布式并行处理特征数据，并将生成的 Embedding 传给 TensorFlow 完成模型训练。

4.4.1 分布式文件系统 HDFS

由于系统中主要使用 HDFS 作为分布式文件存储，而 MapReduce 的任务被 Spark 取代，在此主要介绍以下 HDFS 实现高可用的原理。

HDFS 从设计之初就假设存储节点并不可靠，并设计了心跳检测、数据冗余备份等机制来帮助节点在发生故障时及时发现并恢复。HDFS 的主要组件包括一个 namenode 和其管理的多个 datanode，以及 Secondarynamenode 检测节点。

1. Namenode(NN)：HDFS 的唯一主节点。主节点可以跟踪文件，管理文件系统，并在其中具有所有已存储数据的元数据。并直接与客户端联系。

2. Secondarynamenode(SN)：名称节点的检查节点。指示名称节点创建并向其发送镜像文件和操作日志，然后由 SN 创建压缩镜像。当主节点出现故障时，SN 会利用备份的镜像文件帮助其快速恢复。

3. Datanode（DN）：数据节点。每 3 秒向主节点报告一次，超过 2 分钟将被视为掉线，这时由其他节点上存储的备份数据会重新构建一个 DN。

下图 2-2 展示了 HDFS 的组织架构：

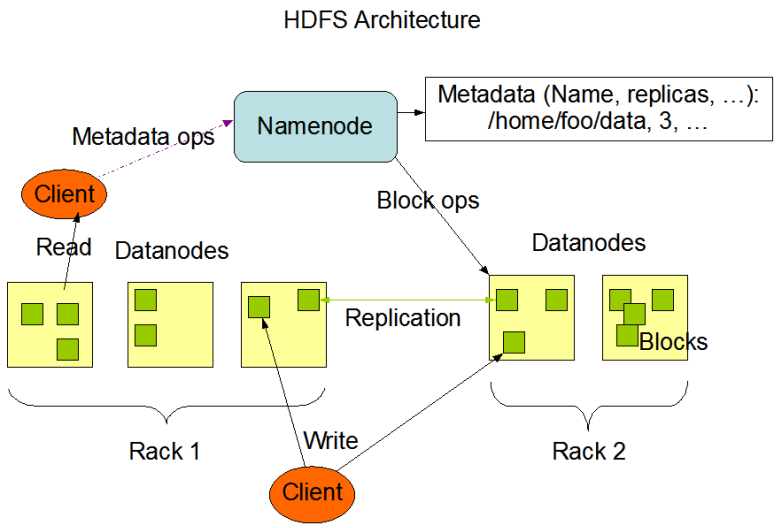

图 4-2 HDFS 架构图

4.4.2 分布式计算平台 Spark

Spark 生态系统如下图 2-3 所示：

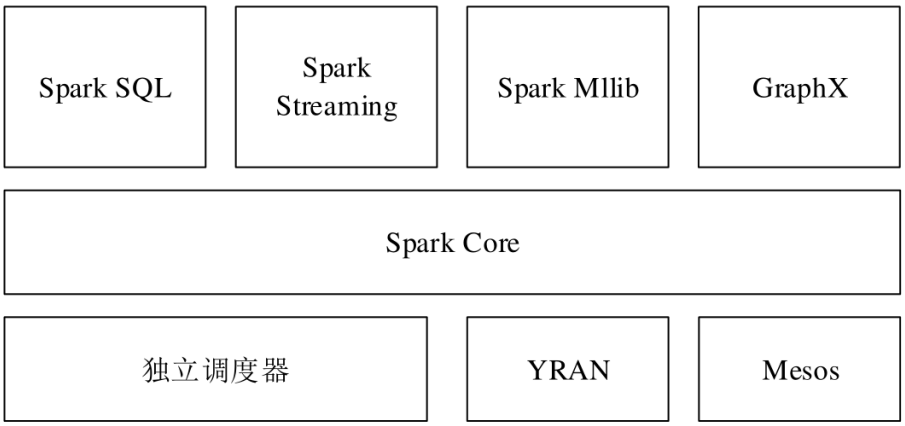

图 4-3 Spark 生态系统

Spark 是一个面向内存的计算框架，这使得它的计算效率远远超过 MR 任务。而 SparkSQL 更是在此基础上抽象出 DataFrame 数据结构，并为其做了大量的性能优化，使得 Python/Java 等语言有了等同于原生 scala 编程的执行效率。

下表 2-4 列出了 Spark 各个模块的功能：

表 4-4 Spark 各模块功能表

模块名	功能
Spark Core	**Spark Core** 定义操作 RDD 的相关 API，实现内存管理、错误恢复、任务调度、与存储系统交互等基础功能。
Spark SQL	**Spark SQL** 用于操作各种结构化数据，通过 Spark SQL，可以使用 SQL 来查询或修改数据。
Spark Streaming	**Spark Streaming** 作为流式计算组件，定义用于操作实时数据流的相关 API。
Spark MLlib	**Spark MLlib** 定义一些常见的机器学习相关算法和功能，如分类、聚类、回归分析、协同过滤等，同时支持数据导入、模型评估等额外功能。
集群管理器	**集群管理器**负责整个集群的资源管理以及节点之间的通信，从而灵活地实现集群规模的伸缩扩展。Spark 支持在 Hadoop YARN、Apache Mesos 等多种集群管理器上部署和运行。

4.5 推荐模块

4.5.1 模型训练 TensorFlow

4.5.2 模型线上服务 TensorFlow Serving

4.6 系统业务模块

4.6.1 前端框架 Vue

4.6.2 后端框架 Gin

4.7 本章小结

本章主要建立了……
，给出了……，对……进行了推导……

第5章 程序设计竞赛组队推荐系统实现

5.1 环境部署

5.1.1 开发环境

5.1.2 部署环境

5.2 算法实现与结果分析

5.3 系统实现

5.4 本章小结

结论

[单击此处输入结论]

致谢

[单击此处输入致谢]

参考文献

[1] 中国互联网络信息中心(CNNIC). 第 47 次中国互联网络发展现状统计报告[R]. 2021 年 2 月 3 日.
[2] 周晓琳,解静,刘勇,尤枫,吴佳伟.面向程序设计竞赛的人才培养模式实践与探索[J].大学教育,2020(07):144-146.
[3] GOLDBERG D, NICHOLS D, OKI B M. Using collaborative filtering to weave an information tapestry[J]. Communications of the ACM, 1992, 35(12): 61–70. DOI:10.1145/138859.138867.
[4] GREG L, BRENT S, JEREMY Y. Industry report: Amazon.com recommendations: Item-to-item collaborative filtering[J]. IEEE Distributed Systems, 2003: 76–80.
[5] Gai K, Zhu X, Li H, et al. Learning piece-wise linear models from large scale data for ad click prediction[J]. arXiv preprint arXiv:1704.05194, 2017.
[6] Rendle S. Factorization machines[C]//2010 IEEE International Conference on Data Mining. IEEE, 2010: 995-1000.
[7] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
[8] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[J]. arXiv preprint arXiv:1310.4546, 2013.
[9] Barkan O, Koenigstein N. Item2vec: neural item embedding for collaborative filtering[C]//2016 IEEE 26th International Workshop on Machine Learning for Signal Processing (MLSP). IEEE, 2016: 1-6.
[10] Grover A, Leskovec J. node2vec: Scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.
[11] Wang J, Huang P, Zhao H, et al. Billion-scale commodity embedding for e-commerce recommendation in alibaba[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 839-848.
[12] 张廉月. 基于 Flink 的电影推荐系统的研究与实现[D]. 电子科技大学, 2020.
[13] 景坤. 网约车竞赛平台的设计与实现[D]. 北京交通大学, 2019.
[14] 胡开冉. 基于 Hadoop/Spark 的反向推荐算法研究[D]. 成都理工大学, 2018.
[15] 李斌. 面向学科竞赛的组队平台研究[D]. 华中师范大学, 2020.
[16] Toledo R Y, Mota Y C. An e-learning collaborative filtering approach to

suggest problems to solve in programming online judges[J]. International Journal of Distance Education Technologies (IJDET), 2014, 12(2): 51-65.
[17] Yera Toledo R, Caballero Mota Y, Martínez L. A recommender system for programming online judges using fuzzy information modeling[C]//Informatics. Multidisciplinary Digital Publishing Institute, 2018, 5(2): 17.
[18] Caro-Martinez M, Jimenez-Diaz G. Similar users or similar items? Comparing similarity-based approaches for recommender systems in online judges[C]//International Conference on Case-Based Reasoning. Springer, Cham, 2017: 92-107.
[19] FANTOZZI P, LAURA L. Recommending Tasks in Online Judges using Autoencoder Neural Networks[J]. 2020.
[20] 朱国进, 凌晓晨. 基于关联规则挖掘的 OJ 推荐方法[J]. 收藏, 2018, 2.
[21] 孙权, 贺细平. 协同过滤算法在 ACM 在线评测推荐系统中的应用研究[J]. 电脑与信息技术, 2015, 6.
[22] 肖春芸, 贺樑, 窦亮, 等. 基于 Online Judge 进行程序设计类课程实践的混合推荐[J]. 现代计算机, 2019.
[23] Hoare C A R. Communicating sequential processes[J]. Communications of the ACM, 1978, 21(8): 666-677.

附录 A

附录 B

附录 C